

Descripción general de la arquitectura de data lakehouse

Los profesionales de datos en la nube trabajan con diversas fuentes de datos, incluidos datos estructurados, no estructurados y semiestructurados, que se almacenan de distintas formas. Por ello, crear una arquitectura que admita esos datos puede ayudar a tu organización a usarlos para obtener estadísticas y tomar decisiones. Comprender cómo y por qué se almacenan los datos también te ayudará a diseñar, implementar y conservar arquitecturas de datos en la nube, y a analizar datos de la nube. En esta lectura, obtendrás más información sobre los data lakes y cómo estos y las herramientas en la nube posibilitan los data lakehouses.

¿Qué es un data lake?

Hasta ahora, aprendiste que un data lake es un sistema de almacenamiento en el que se almacenan grandes cantidades de datos en su formato original sin procesar hasta que se necesiten. Tal como el almacén de datos tradicional, en un data lake, se combinan muchas fuentes diferentes y se almacenan en un solo lugar. Si bien los almacenes de datos tienen jerarquías, los data lakes son planos. En ellos, los datos se etiquetan para identificarse, pero no se organizan. Como son fluidos, se denominan data lakes (“lake” significa “lago” en inglés). Además, los data lakes no requieren que los datos se transformen antes de almacenarse, por lo que son útiles si tu sistema transfiere muchos tipos de datos diferentes.

Los data lakes también conllevan desafíos. Por ejemplo, se necesita mucho procesamiento para que los datos del almacenamiento sean útiles, lo que requiere una inversión en recursos. También es más difícil garantizar la calidad de los datos, ya que no se limpian de inmediato, lo que dificulta garantizar que se cumplan los estándares organizativos y que sean útiles los datos que se transfieren. Además, consultar data lakes es menos eficiente debido a la forma en que se organizan los datos, que hace que sea más complejo encontrar lo que se solicita.

Aquí es donde entra la arquitectura de data lakehouse. Con la arquitectura de lakehouse, se aprovechan al máximo los almacenes de datos tradicionales y la flexibilidad de los data lakes.

Componentes de la arquitectura de data lakehouse

Los data lakehouses son arquitecturas de datos híbridas en las que se combinan las funciones de los data lakes con las de los almacenes de datos. Se aprovechan las ventajas de los almacenes de datos y las de los data lakes para mejorar las funciones de administración de

datos, integrar perfectamente las herramientas de estadísticas, promover la escalabilidad y flexibilidad, y admitir varias cargas de trabajo de manera eficiente. La arquitectura de lakehouse tiene cinco capas: transferencia, almacenamiento, metadatos, API y consumo. Consulta la tabla para conocer cómo cada una de ellas desempeña un papel importante en la funcionalidad general de los lakehouses:

Capa	Funciones
Transferencia	Recupera datos de distintas fuentes y los transporta a la capa de almacenamiento.
Almacenamiento	Almacena datos sin procesar para que los usuarios y las herramientas tengan acceso directo a los datos cuando los necesiten.
Metadatos	Cataloga metadatos sobre datos almacenados para habilitar una administración coherente de datos y esquemas.
API	Organiza APIs, estadísticas y herramientas de procesamiento para ejecutar trabajos fácilmente.
Consumo	Existe como la capa superior, que puede acceder a las capas de almacenamiento, metadatos y API para ejecutar trabajos de análisis.

Conclusiones principales

La nube dio pie a muchas soluciones innovadoras y nuevas para almacenar datos y acceder a ellos. A medida que las organizaciones usan más la nube en sus sistemas de datos, se desarrollan más soluciones. La arquitectura de data lakehouse es solo un ejemplo de cómo innovar en soluciones de almacenamiento. Los analistas de datos en la nube tienen la oportunidad de explorar las arquitecturas de datos en la nube y encontrar soluciones para sus organizaciones.