

Función de linaje de datos de Dataplex

Ya aprendiste que una fuente de datos es el lugar donde se generan los datos. Para muchas organizaciones, administrar múltiples fuentes de datos puede ser una tarea compleja, por lo general, requiere esfuerzos exhaustivos para rastrear los datos desde su punto de origen hasta su estado actual. En esta lectura, aprenderás más sobre el proceso de seguimiento de datos y cómo puedes lograrlo con la función de linaje de Dataplex.

Seguimiento del linaje de datos

El seguimiento de datos incluye el seguimiento de metadatos específicos que proporcionan información sobre la ruta que recorrieron los datos durante su ciclo de vida. Es decir, el seguimiento del linaje de datos se inicia con averiguar de dónde vienen los datos, hacia dónde fueron y qué transformaciones sufrieron. Los servicios como Dataplex incluyen funciones de linaje de datos integradas que crean gráficos con los metadatos de los conjuntos de datos.

La importancia del linaje de datos

El linaje de datos tiene varios objetivos además de encontrar las versiones anteriores de los datos. El seguimiento del linaje ayuda a entender cómo se originan y transforman los datos, a realizar el seguimiento de los errores en los datos y en la entrada de datos, y permitir la administración de cambios.

El linaje de datos puede admitir el cumplimiento de las normativas y las reglamentaciones de privacidad. Puede ayudarte a asociar los puntos de acceso a los datos y entender cómo se modificaron los datos durante su ciclo de vida, ya que proporciona un registro de estos cambios. El linaje de datos también se puede usar para auditorías e informes de resumen.

Gráfico de linaje de datos

Dataplex crea un gráfico de linaje de datos para visualizar los cambios en los datos. El modelo del linaje de datos contiene tres tipos de información: procesamiento, ejecución y evento.

Procesamiento

Un procesamiento de datos es una operación de transformación que se le realizó a un conjunto de datos. Un procesamiento de datos puede incluir la revisión o la manipulación de datos, por ejemplo, la normalización del conjunto de datos, el resumen de los datos o el ordenamiento e indexación de datos. Es posible que un procesamiento de datos incluya la combinación o la separación de un conjunto de datos.

Ejecución


Una ejecución es un registro de cuándo se ejecutó el proceso. Cada procesamiento puede tener una o más ejecuciones. Los detalles de la ejecución incluyen la hora de inicio y de finalización del procesamiento y cualquier otro detalle determinado por la organización.

Evento

Un evento es lo que sucede cuando se lleva a cabo la transformación de datos. El evento de transformación de datos ocurre cuando los datos se mueven desde la fuente hasta el destino final. Un evento también incluye información como un vínculo a la fuente de entrada.

Componentes de un gráfico de linaje

El gráfico de linaje de Dataplex crea una representación visual de cómo diferentes servicios en línea procesaron los datos. El gráfico crea un ícono rectangular para cada versión de un conjunto de datos. Además, incluye íconos que indican el servicio que se usó para transformar los datos. Las flechas indican movimiento y todas las combinaciones de datos.



El gráfico de linaje de Dataplex ilustra dónde Cloud Composer procesó la tabla 1 y la transformó en la tabla 2. Los íconos que representan Cloud Composer y BigQuery son comunes a los gráficos de linaje de datos de Dataplex e indican qué servicios procesaron los datos.

Conclusiones principales

La función de linaje de Dataplex te permite hacer el seguimiento y visualizar los cambios realizados a tus conjuntos de datos. Usa los metadatos existentes de tus conjuntos de datos para buscar los cambios o las manipulaciones que se le hicieron a los datos y crea un registro para tomar nota de los cambios a los conjuntos de datos. Las herramientas de visualización crean un mapa que muestra cómo se transforman los datos y cómo llegaron a su estado actual. Esta función puede ser muy útil para la detección de errores, la edición y el cumplimiento.

Recursos para obtener más información

Para obtener más información sobre cómo los gráficos de linaje de datos de Dataplex pueden asistir en tu trabajo como analista de datos, consulta estos vínculos:

- El blog de Google Cloud ofrece información para entender la función de linaje de datos de Dataplex:

<https://cloud.google.com/blog/products/data-analytics/announcing-dataplex-data-lineage-in-ga>