

Cómo administrar clústeres de Dataproc

Hasta ahora, aprendiste que Dataproc es un servicio completamente administrado y muy escalable que maximiza las herramientas de datos de código abierto para el procesamiento por lotes, consultas, transmisiones y aprendizaje automático, como Apache Hadoop y Apache Spark. Dataproc se usa para la modernización de los data lakes, ETL y ciencia de datos segura. También aprendiste cómo crear un clúster de Dataproc en el servicio de Compute Engine de Google Cloud. En esta lectura, aprenderás más sobre la administración de clústeres de Dataproc, incluido cómo empezar y detener un clúster y cómo agregar una etiqueta con un clúster.

Administra clústeres

Los clústeres están compuestos por nodos o servidores dedicados a alojar solo los recursos de computación necesarios para ejecutar tu clúster individual. Cuando trabajas con clústeres, es posible que tengas que aumentar o disminuir la cantidad de nodos. Cuando necesitas que un trabajo se ejecute más rápido, aumentar los nodos aumenta la potencia de procesamiento y la cantidad de datos que pueden procesarse en paralelo. Este es un aspecto de la administración de clústeres. Entre otros aspectos de la administración de clústeres están incluidos empezar y detener clústeres, apagar un clúster y agregar una etiqueta a un clúster.

Empieza y detén un clúster

Si no estás trabajando de manera activa con conjuntos de datos en un clúster, puedes detenerlo para evitar cargos por los recursos de procesamiento usados para ejecutarlo. Para detener un clúster, debes hacer lo siguiente:

1. Navega a la página de clústeres de Dataproc en la consola de Google Cloud.
2. Haz clic en DETENER para detener el clúster.

Nota: Si tienes operaciones o trabajos activos, como actualizaciones, tu clúster no se detendrá.

Para iniciar el clúster de nuevo, tienes que navegar a la misma página y hacer clic en INICIAR.

Borra un clúster

Cuando ya no necesitas un clúster, puedes borrarlo de forma permanente. Para borrar un clúster, haz lo siguiente:

1. Navega a la página de clústeres de Dataproc en la consola de Google Cloud.
2. Selecciona el clúster haciendo clic en la casilla junto al nombre.
3. Haz clic en DELETE (BORRAR) en la barra de menú superior.

Clusters + CREATE CLUSTER ↺ REFRESH ▶ START ■ STOP 🗑️ DELETE

≡ Filter Search clusters, press Enter

☒	Name ↑	Status	Region	Zone	Total worker nodes	Flexible VMs?
☒	mycluster	✓ Running	us-west1	us-west1-c	0	No

Agrega una etiqueta a un clúster

Cuando trabajas con varios clústeres, las etiquetas de clústeres pueden ayudarte a organizar tus cargas de trabajo. Las etiquetas son pares clave-valor que pueden asignarse a clústeres de Dataproc y trabajos. Las etiquetas te permiten ordenar y filtrar los clústeres. Puedes etiquetar los clústeres por proyecto, usuario o cualquier otra categoría que necesite tu equipo, o etiquetarlos como activos o inactivos.

Puedes usar la consola de Google Cloud para agregar etiquetas a un clúster de Dataproc en cualquier momento antes o después de la creación y puedes agregar una etiqueta de trabajo solo a la hora del envío. También tienes la opción de habilitar las etiquetas que se aplican automáticamente. Una vez que hayas creado tus etiquetas, puedes modificarlas. Para agregar o borrar una etiqueta en un clúster existente, sigue los pasos a continuación:

1. En la consola de Google Cloud, navega a un clúster y haz clic en SHOW INFO PANEL (MOSTRAR PANEL DE INFORMACIÓN).

Clusters + CREATE CLUSTER ↺ REFRESH ▶ START ⋮ SHOW INFO PANEL

≡ Filter Search clusters, press Enter ?

☒	Name ↑	Status	Region	Zone	Total worker nodes	Flexible VMs?
☒	mycluster	✓ Running	us-west1	us-west1-c	0	No

2. Agrega o borra etiquetas en el panel LABELS (ETIQUETAS).

The screenshot shows the Google Cloud Clusters console. On the left, a table lists clusters. The cluster 'mycluster' is selected, and its checkbox is highlighted with a red box. On the right, the 'LABELS' tab is active, also highlighted with a red box. The 'LABELS' panel shows a description of labels and a form to add a new label. The form has a 'Key' field with the value 'goog-dataproc-autozone' and a 'Value' field with the value 'enabled'.

Name	Status	Region
☒ mycluster	Running	us-west1

Labels help organize your resources (e.g., cost_center:sales or env:prod).

Label 1

Key 1
goog-dataproc-autozone

Value 1
enabled

3. Haz clic en Guardar.
4. Para buscar clústeres con etiquetas, navega a la página de lista de clústeres y usa la barra de búsqueda para establecer tus criterios de filtros.

The screenshot shows the Google Cloud Clusters console. The search bar is highlighted with a red box. The search bar contains the text 'Search clusters, press Enter'. Below the search bar, a table lists clusters. The cluster 'mycluster' is selected, and its checkbox is highlighted with a red box. The table has columns for Name, Status, Region, Zone, Total worker nodes, and Flexible VMs?.

Name	Status	Region	Zone	Total worker nodes	Flexible VMs?
☒ mycluster	Running	us-west1	us-west1-c	0	No

Conclusiones principales

Los clústeres de Dataproc hacen que procesar por lotes, realizar consultas y transmitir datos con Dataproc sean acciones eficientes y organizadas. Junto con la habilidad de crear clústeres, Dataproc también te permite iniciar y detener clústeres o borrarlos de forma permanente, según sea necesario. También puedes agregar etiquetas a tus clústeres, que te ayuden a organizar tus cargas de trabajo. La administración de Dataproc se lleva a cabo en la consola de Google Cloud, por lo cual todas las opciones de administración son posibles en la consola.

Recursos para obtener más información

Para obtener más información sobre la administración de clústeres de Dataproc, incluida la administración mediante la interfaz de línea de comandos, consulta los vínculos a continuación:

- En Google Cloud se ofrecen documentos para crear y administrar etiquetas en Dataproc: <https://cloud.google.com/dataproc/docs/guides/creating-managing-labels>
- En los documentos de Google Cloud también se ofrece información sobre iniciar y detener clústeres en Dataproc: <https://cloud.google.com/dataproc/docs/guides/dataproc-start-stop>